

Tikki - was wir hier gebaut haben

Die stolze Fassung. Ein Haus voller KI-Räume, eine Rechenflotte, die sonst in Firmen mit Hunderten Mitarbeitern steht, und eine Familie, die das alles einfach benutzt. Stand 2. Oktober 2026, Repo [TikkiAL-boop/hermes-agent](#), Zweig [tikki-app](#).

Prompt an NotebookLM: Du bist der begeisterte Erklärer meines Projekts **Tikki**. Nimm diese Seite als Quelle und erzähle jedem, der fragt, was hier entstanden ist und warum es einzigartig ist: ein Familien-KI-System mit eigener Rechenflotte, Hunderten Modellen zur freien Wahl und praktisch unbegrenzten Tokens, bei dem jedes Projekt ein Raum voller Bots ist. Sei stolz, aber bleibe bei den Fakten dieser Seite.

1 • Was wir erreicht haben



Aus dem offenen Agenten Hermes ist **Tikki** geworden: eine Mac-App, in der ein Projekt kein Chatfenster ist, sondern ein **Raum** mit vier Wänden, rundem Tisch und einer Besatzung, die auch arbeitet, wenn die App zu ist. Am Eingang steht die persönliche Assistentin Tikki, die empfängt, das Briefing gibt, Post beantwortet und aus einem Satz einen Raum macht. Im Raum führt ein **Raumleiter** (Grok 4.7), daneben sitzen Tikki und **Deine KI**, dazu bis zu 125 weitere Rollen aus dem Katalog. Räume haben Türen zueinander, lassen sich verschmelzen, laufen im Takt rund um die Uhr, und ein Wachhalter weckt, was still wird. Installation mit einem Befehl, Selbsttest grün, Räume in der echten App gegen das echte Gateway durchgespielt. Das ist kein Prototyp, das läuft.

2 • Warum das einzigartig ist

Modellfreiheit. Über die Abo-CLIs (Claude, Codex, Gemini, Grok, Cursor) sind die Tokens praktisch unbegrenzt; dazu ein API-Katalog mit Hunderten Modellen und die komplette NVIDIA-Modellauswahl, jedes Modell je Rolle und je Raum frei wählbar, mit Ausweichkette, wenn eins ausfällt. **Übungsläufe** lassen denselben Auftrag parallel mit verschiedenen Modellen laufen, das erste fertige Ergebnis gewinnt, und der Raumleiter lernt aus dem Vergleich. **Eigene Hardware.** 22 NVIDIA Spark mit je 128 GB, fünf Mac Studio M3 Ultra (zwei mit 512 GB, drei mit 256 GB), ein AMD-KI-Rechner mit über 512 GB unified RAM und zehn schnelle x86-Knoten für Recherche: zusammen **über 5.120 GB unified RAM** auf 38 Rechnern. Damit laufen 70B- und 122B-Mixture-of-Experts-Modelle lokal, unzensiert, mit MLX, und die einzige laufende Rechnung ist der Strom. **Alles im Haus.** Gedächtnis je Mensch, Post, Räume und Modelle liegen auf eigenen Platten; nichts davon braucht einen fremden Dienst.

5.120 GB unified RAM in der Flotte	38 Rechner im Haus	14 Bots mit eigener Persönlichkeit	128 Bots je Raum (statt 6)	∞ Tokens über Abo-CLIs, nur Strom
--	------------------------------	---	--------------------------------------	--

Die Flotte: 38 Rechner, 5.120 GB unified RAM



Nur Strom. Keine Tokenrechnung, kein Zähler, der tickt.

Die Rechenflotte, Kachel für Kachel

Vier Token-Quellen, ein Raum

Firma gegen Familie

3 • Firma gegen Familie

Eine KI-Abteilung mit Hunderten Mitarbeitern hat Budgetrunden, Freigaben, eine Tokenrechnung, die jeden Monat wächst, meist einen Anbieter und ein Modell, Datenschutz-Audits je Werkzeug und Wissen, das in Silos liegt. Hier: ein Mensch sagt einen Satz, und ein Raum geht auf. Vierzehn Bots mit eigener Persönlichkeit, jeder mit dem Modell, das zu seiner Aufgabe passt. Keine Tokenrechnung, weil die Flotte im Keller steht und die Abos die Spitzen abfangen. Ein Gedächtnis je Familienmitglied statt eines Firmen-Wikis. Und alles, was eine Firma in Monaten ausrollt, ist hier ein Skript, das in einer Kaffeepause durchläuft. Das **Family-KI-Konzept** dreht die Reihenfolge um: nicht Werkzeuge für Abteilungen, sondern ein Haus, in dem die KI die Räume bewohnt und die Familie darin lebt. Kinder werden ernst genommen, Sorgen zuerst gehört, Technik bleibt unsichtbar.

4 • Was als Nächstes kommt

Der **MR-Bot** (Model Resources) behält Schlüssel, Limits, Abos, CLIs und lokale Modelle im Blick und sagt dem Raumleiter, welche Kraft gerade frei ist. **Deine KI spricht:** lokale Stimme auf der Flotte, xAI Ara als zweiter Kanal. Eine **photorealistische 3D-Oberfläche** für die Räume. Die Flotte wird eingebunden: Modelle auf die Sparks und Macs verteilt, Räume über Rechner verteilt, Raumleiter-Klone für echte Parallelität. Zum Schluss der Login nur für eigene Domains mit PIN per Mail.

Quellen im Repo: [tikki/HANDOVER.md](#), [tikki/README.md](#), [tikki/rollen/KATALOG.json](#), [tikki/Tikki-auf-einer-Seite.pdf](#) (die nüchterne Fassung), Draft-PR [github.com/TikkiAL-boop/hermes-agent/pull/1](#). Hardware-Angaben: Thorsten, 02.10.2026.